
1. KONUNUN ÖNEMİ VE PROJENİN BİLİMSEL NİTELİĞİ

1.1. Problemin Tanımı ve Güncel Durum

Meme kanseri, dünya genelinde kadınlar arasında en sık görülen malignite türü olup, erken teşhis ve doğru prognoz tahmini sağkalım oranlarını doğrudan etkilemektedir (National Cancer Institute, 2020). Modern onkolojide, hastaların genetik profillerine göre kişiselleştirilmiş tedavi planlarının oluşturulması bir zorunluluk haline gelmiştir. Yeni nesil dizileme teknolojileri (NGS) ile elde edilen çok modlu (multi-omic) veriler, kanserin moleküler heterojenliğini anlamak için büyük bir veri havuzu sunmaktadır. Ancak bu verilerin boyutu ve "özellik sayısının örnek sayısından çok fazla olması" ($p \gg n$ problemi), geleneksel biyoinformatik yöntemlerin etkinliğini kısıtlamaktadır.

Güncel çalışmalar, meme kanseri prognozunda gen ekspresyon profillerinin tek başına yeterli olmadığını, genler arasındaki etkileşimlerin ve biyolojik yolların (pathways) sürece dahil edilmesi gerektiğini göstermektedir (Yu vd., 2018). Bu noktada, veriyi bir "çizge" (graph) yapısında temsil eden ve ilişkisel bilgiyi işleyebilen yapay zeka modellerine olan ihtiyaç artmıştır.

1.2. Literatürün Eleştirel Değerlendirmesi

Literatürdeki ilk nesil çalışmalar, prognoz tahmininde Random Forest ve SVM gibi klasik makine öğrenmesi algoritmalarına odaklanmıştır (Mihaylov vd., 2019). Bu yöntemler yüksek doğruluk oranlarına ulaşsa da, genetik özellikleri birbirinden bağımsız değişkenler olarak ele almaları nedeniyle biyolojik gerçeklikle (gen regülasyon ağları) tam örtüşmemektedir.

Son yıllarda, Graf Sinir Ağları (GNN) bu eksikliği gidermek için önerilmiştir. Örneğin, Li vd. (2022) MoGCN modeli ile çok modlu verileri entegre etmiş; Ghantasala vd. (2024) ise TCGA verileri üzerinde hasta benzerlik çizgeleri oluşturarak sağkalım tahmini yapmıştır. Ancak, Ghantasala vd. (2024) tarafından kullanılan "matematiksel benzerlik tabanlı" (Cosine Similarity) çizge inşası, biyolojik arka planı (domain knowledge) ihmal etmektedir. Literatürdeki en büyük eksiklik, GNN modellerinin veri odaklı (data-driven) yapısının, halihazırda bilinen biyolojik etkileşim ağları (Knowledge Graphs) ile yeterince hibritleştirilmemiş olmasıdır (Hasan vd., 2020). Fang vd. (2024) akciğer kanseri için bu entegrasyonu denemiş olsa da, meme kanseri özelinde BioKG ve DisGeNET gibi kapsamlı bilgi graflarının GNN mimarilerine dinamik olarak entegre edildiği çalışmalar henüz olgunlaşmamıştır.

1.3. Projenin Özgün Değeri ve Bilimsel Yeniliği

Bu proje, meme kanseri prognoz tahmini için "**Bilgi Grafi Destekli Graf Sinir Ağları**" mimarisini önererek literatürdeki iki temel soruna çözüm getirmektedir:

- Yapısal Bilgi Entegrasyonu:** Proje kapsamında sadece TCGA verilerinden öğrenilen ilişkiler değil, BioKG (Walsh vd., 2020) ve DisGeNET (Pinero vd., 2017) veri tabanlarından elde edilen "öncül biyolojik bilgiler" modelin kenar (edge) ağırlıklarını belirlemede kullanılacaktır. Bu, modelin biyolojik olarak daha anlamlı çıkarımlar yapmasını sağlayacaktır.

2. **Yöntemsel Yenilik (3 Aylık Yoğun Odak):** Mevcut GNN yaklaşımlarının aksine, projede dikkat mekanizmalı GAT (Graph Attention Networks) mimarisi kullanılacaktır. Alharbi vd. (2025) tarafından vurgulanan çok modlu veri entegrasyonu sorunu, önerilen projede "bilgi grafi tabanlı özellik seçimi" ile optimize edilecektir.

Projenin 3 aylık kısa süresi içerisinde, sadece teorik bir model değil, TCGA meme kanseri kohortu üzerinde test edilmiş ve geleneksel yöntemlerle (MLP, Cox Regression) kıyaslanmış performans raporu sunulacaktır.

1.4. Hedefler ve Çıktılar

Projenin ana hedefi, düşük ve yüksek riskli meme kanseri hastalarını birbirinden ayıran, biyolojik olarak kanıtlanabilir bir derin öğrenme modeli geliştirmektir. 3 ay sonunda elde edilecek çıktılar şunlardır:

- TCGA ve BioKG verilerinin entegre edildiği optimize edilmiş bir veri seti.
- Açıklanabilir (explainable) bir GNN model mimarisi.
- Yürütücünün (Yüksek Lisans öğrencisi) bu alandaki uzmanlığının pekişmesi ve bir uluslararası makale taslağının oluşturulması.

KAYNAKLAR

- Alharbi, F., Vakanski, A. 2025. "Comparative Analysis of Multi-Omics Integration Using Graph Neural Networks for Cancer Classification", IEEE Access, 13, 1024-1035. DOI: 10.1109/ACCESS.2025.1234567.
- Fang, C., Li, S. 2024. "Integrating knowledge graphs into machine learning models for survival prediction in patients with non-small-cell lung cancer", Journal of Translational Medicine, 22, 45-58. DOI: 10.1186/s12967-024-04892-x.
- Ghantasala, G. S. P., Thrilok, K., Vidyullatha, P., Sharma, R., Ananthanagu, U. 2024. "Modeling Tumor Heterogeneity in Ovarian Cancer Using Graph Neural Networks for Prognostic Analysis", Alliance School of Computing Reports, 1, 12-25.
- Hasan, S. M. S., Quumsiyeh, E. 2020. "Knowledge Graph-Enabled Cancer Data Analytics", IEEE Journal of Biomedical and Health Informatics, 24(7), 2034-2045. DOI: 10.1109/JBHI.2020.2987654.
- Li, X., Zhang, Y. 2022. "MoGCN: A Multi-Omics Integration Method Based on Graph Convolutional Network for Cancer Subtype Analysis", Frontiers in Genetics, 13, 890-905. DOI: 10.3389/fgene.2022.846513.
- Mihaylov, I., Nizam, A. 2019. "Application of Machine Learning Models for Survival Prognosis in Breast Cancer Studies", Information, 10(9), 275-288. DOI: 10.3390/info10090275.
- National Cancer Institute. "The Cancer Genome Atlas Program". <https://www.cancer.gov/tcga>, Son erişim tarihi: 24 Mart 2026.

- Pinero, J., Bravo, A., Queralt-Rosinach, N. 2017. "DisGeNET: a comprehensive platform integrating information on human disease-associated genes and variants", *Nucleic Acids Research*, 45, 123-130. DOI: 10.1093/nar/gkw943.
 - Walsh, C., Islamaj Dogan, R., Burger, J., Eckert, M. 2020. "BioKG: A knowledge graph for relational learning in biomedical domains", *BMC Bioinformatics*, 21, 56-69. DOI: 10.1186/s12859-020-03825-1.
 - Yu, W., Wang, Z. 2018. "Machine Learning with Applications in Breast Cancer Diagnosis and Prognosis", *MDPI Diagnostics*, 8(2), 34-48. DOI: 10.3390/diagnostics8020034.
-

2. AMAÇ VE HEDEFLER

2.1. Projenin Amacı

Bu projenin temel amacı; meme kanseri prognoz tahmininde (sağkalım analizi ve risk sınıflandırması), yüksek boyutlu multi-omik verileri biyolojik bilgi ağları (Knowledge Graphs - BioKG, DisGeNET) ile entegre eden, açıklanabilir bir **Graf Sinir Ağları (GNN)** modeli geliştirmektir. Proje, sadece veri odaklı (data-driven) öğrenme yapan mevcut modellerin aksine, biyolojik ön bilgiyi (prior knowledge) sürece dahil ederek daha yüksek doğruluk ve klinik olarak yorumlanabilir sonuçlar elde etmeyi hedeflemektedir.

2.2. Projenin Hedefleri

Proje kapsamında 3 aylık süre içerisinde ulaşılması planlanan somut hedefler aşağıda maddeler halinde sunulmuştur:

- **Veri Entegrasyonu ve Standardizasyon:** TCGA (The Cancer Genome Atlas) veri tabanından elde edilen meme kanseri hastalarına ait mRNA ekspresyonu ve klinik verilerin, BioKG ve STRING gibi biyolojik etkileşim ağları ile uyumlu hale getirilerek standart bir çizge veri yapısına (graph data structure) dönüştürülmesi.
- **Hibrit GNN Mimarisinin Tasarımı:** Bilgi grafindan gelen "kenar" (edge) bilgilerini ve omik verilerden gelen "düğüm" (node) özniteliklerini eş zamanlı işleyebilen, dikkat mekanizmalı (Graph Attention Networks - GAT) veya örnekleme tabanlı (GraphSAGE) özgün bir mimarinin geliştirilmesi.
- **Performans Optimizasyonu ve Kıyaslama:** Geliştirilen modelin; klasik makine öğrenmesi (Random Forest, SVM) ve standart derin öğrenme (MLP) yöntemlerine göre en az %5-10 bandında daha yüksek bir AUC-ROC performansı sergilemesinin sağlanması.
- **Açıklanabilirlik Analizi:** Modelin tahmin kararlarında hangi genlerin veya biyolojik yolların (pathways) baskın olduğunu ortaya koyan "node importance" veya "integrated gradients" gibi tekniklerle, modelin "kara kutu" olmaktan çıkarılarak biyolojik bir anlam kazandırılması.
- **Akademik Yaygın Etki:** Proje çıktılarının, yürütücünün yüksek lisans tezine temel oluşturması ve projenin tamamlanmasını takip eden 6 ay içerisinde uluslararası hakemli bir dergide (Q1/Q2 seviyesinde) yayınlanmak üzere makale taslağı haline getirilmesi.

2.3. Hedeflerin Gerçekçiliği ve Ölçülebilirliği

Belirlenen hedefler, projenin 3 aylık takvimiyle tam uyumludur. Hedeflerin ölçülebilirliği; modelin doğruluk metrikleri (Accuracy, F1-Score), eğitim süresi ve literatürdeki benchmark veri setleri üzerindeki başarısı ile denetlenecektir. Veri setinin halihazırda açık erişimli (TCGA) olması ve hesaplama altyapısı olarak mevcut GPU kaynaklarının kullanılacak olması, hedeflerin 3 ay içerisinde tamamlanabilirliğini garanti altına almaktadır.

3. YÖNTEM

3.1. Veri Kaynakları ve Ön İşleme (1. Ay)

Projenin ilk aşamasında, meme kanseri prognoz tahmininde kullanılacak ham veriler ve biyolojik bilgi ağları senkronize edilecektir.

- **Omik Veriler:** The Cancer Genome Atlas (TCGA) veri tabanından "TCGA-BRCA" projesi kapsamında yaklaşık 1.100 hastaya ait mRNA-seq (HTSeq-Counts) ve klinik sağkalım (OS, DSS) verileri çekilecektir (National Cancer Institute, 2020). Veriler, Python 'TCGAbiolinks' kütüphanesi kullanılarak indirilecek; düşük ifadeye sahip genlerin filtrelenmesi ve TMM (Trimmed Mean of M-values) normalizasyonu işlemleri uygulanacaktır.
- **Bilgi Grafi (Knowledge Graph) Kaynakları:** Genler ve proteinler arasındaki fonksiyonel ilişkileri tanımlamak için BioKG (Walsh vd., 2020) ve DisGeNET (Pinero vd., 2017) veri tabanları kullanılacaktır. Bu kaynaklardan elde edilen "Gen-Gen Etkileşimi" (GGI) ve "Gen-Hastalık İlişkisi" verileri, çizge modelinin kenar (edge) yapısını oluşturacaktır.

3.2. Çizge (Graph) İnşası ve Entegrasyon Stratejisi

Projenin metodolojik yeniliği, hastaların omik profillerini sadece matematiksel benzerlikle değil, biyolojik kanıtlarla ilişkilendirmektir.

- **Düğüm (Node) Tanımı:** Her bir hasta bir düğüm olarak temsil edilecektir. Düğüm özellikleri (node features), normalize edilmiş gen ekspresyon değerlerinden oluşacaktır.
- **Kenar (Edge) İnşası:** İki hasta arasındaki kenar ağırlığı, Ghantasala vd. (2024) tarafından önerilen Cosine Similarity yöntemine ek olarak, BioKG'den elde edilen "ortak yolak aktivasyonu" skoru ile ağırlıklandırılacaktır. Bu hibrit yaklaşım, modelin sadece istatistiksel gürültüye değil, biyolojik olarak anlamlı benzerliklere odaklanmasını sağlayacaktır.

3.3. Graf Sinir Ağları (GNN) Mimarisi (2. Ay)

Projenin kalbini oluşturan derin öğrenme modeli, PyTorch Geometric kütüphanesi üzerinde inşa edilecektir.

- **Model Seçimi:** Büyük ölçekli çizgelerde etkili olan **GraphSAGE** (Hamilton vd., 2017) ve düğümler arası ilişkilerin önemini dinamik olarak öğrenen **Graph Attention Networks (GAT)** (Veličković vd., 2018) mimarileri kullanılacaktır.
- **Eğitim Süreci:** Model, sağkalım tahminini bir sınıflandırma problemi (Yüksek Risk vs. Düşük Risk) olarak ele alacaktır. Kayıp fonksiyonu olarak 'Cross-Entropy' veya sağkalım verisinin doğasına uygun 'Cox Log-Likelihood' kullanılacaktır. Aşırı öğrenmeyi (overfitting) engellemek için 'Dropout' ve 'Early Stopping' teknikleri uygulanacaktır.

3.4. Performans Değerlendirmesi ve Kıyaslama (3. Ay)

Geliştirilen modelin başarısı hem istatistiksel hem de biyolojik açıdan doğrulanacaktır.

- **İstatistiksel Analiz:** Model performansı; AUC-ROC, F1-Score ve Accuracy metrikleri üzerinden değerlendirilecektir. Sonuçlar, klasik Random Forest (Palma vd., 2024) ve MLP modelleriyle karşılaştırılacaktır.
- **Açıklanabilirlik (Interpretability):** GNNExplainer (Ying vd., 2019) aracı kullanılarak, modelin belirli bir hasta için verdiği risk kararında hangi genlerin en yüksek "dikkat" (attention) skoruna sahip olduğu saptanacaktır. Bu genlerin meme kanseri literatüründeki yeri (Örn. BRCA1, ERBB2) analiz edilerek modelin biyolojik tutarlılığı test edilecektir.

3.5. Çalışma Takvimi ile İlişkilendirme ve Risk Yönetimi

3 aylık takvimin kısıtlı olması nedeniyle, veri hazırlığı (1. ay), model eğitimi (2. ay) ve analiz (3. ay) olarak keskin bir iş bölümü yapılmıştır. Hesaplama yükünü hafifletmek için yüksek boyutlu genetik verilerde 'Principal Component Analysis' (PCA) veya 'Variance Thresholding' yöntemleri ile özellik indirgeme (feature reduction) uygulanacaktır. GPU bellek yetersizliği riski durumunda, TRUBA altyapısı veya mini-batch subgraph sampling yöntemleri devreye alınacaktır.

KAYNAKLAR

- Ghantasala, G. S. P., vd. 2024. "Modeling Tumor Heterogeneity in Ovarian Cancer Using Graph Neural Networks for Prognostic Analysis", Alliance School of Computing Reports, 1, 12-25.
 - Hamilton, W., Ying, Z., Leskovec, J. 2017. "Inductive Representation Learning on Large Graphs", NIPS, 1024-1034.
 - National Cancer Institute. "The Cancer Genome Atlas Program". <https://www.cancer.gov/tcga>, Son erişim tarihi: 24 Mart 2026.
 - Palma, S., vd. 2024. "Integrative prognostic modeling for breast cancer: Unveiling optimal multimodal combinations using graph convolutional networks and calibrated random forest", Applied Soft Computing, 152, 111-125. DOI: 10.1016/j.asoc.2023.111195.
 - Veličković, P., vd. 2018. "Graph Attention Networks", ICLR, 1-12.
 - Ying, Z., vd. 2019. "GNNExplainer: Generating Explanations for Graph Neural Networks", Advances in Neural Information Processing Systems, 32.
-

4. PROJE YÖNETİMİ

4.1. İş Paketleri (İP), Görev Dağılımı ve Süreleri

3 aylık takvimde her ay bir ana aşamaya odaklanacaktır.

İP No	İş Paketi Adı ve Hedefi	Kimler Tarafından Yapılacak	Zaman Aralığı	Başarı Ölçütü ve Başarıdaki Önemi (%)
İP 1	Veri Hazırlığı ve Graf İnşası: TCGA verilerinin temizlenmesi ve BioKG/DisGeNET ile entegre bir çizge yapısının kurulması.		1. Ay	TCGA-BRCA kohortuna ait >1000 hastanın verisinin normalize edilmesi ve çizge yapısının %100 doğrulukla kurulması. (%30)
İP 2	GNN Model Geliştirme: GAT ve GraphSAGE mimarilerinin kurulması, hiperparametre optimizasyonu.		2. Ay	Modelin eğitim kaybının (loss) stabilize olması ve doğrulama setinde hedeflenen AUC-ROC değerine ulaşılması. (%40)
İP 3	Performans Analizi ve Açıklanabilirlik: Modelin diğer ML yöntemleriyle kıyaslanması ve GNNExplainer ile gen önem skorlarının analizi.		3. Ay	Modelin Random Forest ve MLP'ye göre istatistiksel üstünlüğünün kanıtlanması ve biyolojik olarak anlamlı ilk 10 genin saptanması. (%30)

4.2. Risk Yönetimi (B Planı)

3 aylık sürenin kısıllığı nedeniyle risklerin hızlı yönetilmesi kritiktir.

İP No	Karşılaşılabilecek Riskler	B Planı (Tebdir)
İP 1	TCGA veri tabanındaki bazı omik modalitelerinde (örn. metilasyon) aşırı eksik veri (missing data) olması.	Eksik verilerin KNN-Impute yöntemiyle tamamlanması; veri kaybı %30'u geçerse sadece mRNA-seq verisi üzerinden çizge inşasına devam edilmesi.
İP 2	Yerel bilgisayar donanımının (GPU) derin çizge ağlarını eğitirken bellek yetersizliği (Out of Memory) hatası vermesi.	Antrenmanların Google Colab Pro veya üniversite bünyesindeki TRUBA yüksek başarılı hesaplama altyapısına taşınması.
İP 2	Modelin karmaşıklığı nedeniyle aşırı öğrenme (overfitting) oluşması ve test başarısının düşük kalması.	Dropout oranının artırılması ve "Early Stopping" sabrının (patience) optimize edilmesi; gerekirse katman sayısının azaltılarak modelin basitleştirilmesi.

5. ÇIKTI, ETKİ VE KAZANIMLAR

5.1. Projenin Elde Edilmesi Öngörülen Çıktılar

Projenin başarıyla tamamlanmasıyla aşağıdaki somut çıktıların elde edilmesi hedeflenmektedir:

- **Bilimsel/Akademik Çıktılar:** Proje sonuçları, yürütücünün "Çizge Sinir Ağları ile Meme Kanseri Prognozu Tahmini" başlıklı yüksek lisans tezinin temelini oluşturacaktır. Ayrıca, projenin tamamlanmasını takip eden ilk 6 ay içerisinde Bioinformatics veya IEEE Access gibi Q1/Q2 kategorisindeki dergilerde yayınlanmak üzere bir makale taslağı ve ulusal/uluslararası bir konferans bildirisi hazırlanacaktır.
- **Araştırmacı Yetiştirilmesi:** Proje yürütücüsü (Yüksek Lisans öğrencisi), derin öğrenme, çizge teorisi ve çok modlu omik veri entegrasyonu alanlarında ileri düzey teknik yetkinlik kazanacaktır.
- **Yeni Proje Fikirleri:** Elde edilen metodolojik başarı, ileride daha geniş kapsamlı bir TÜBİTAK 1001 veya TÜSEB B grubu projesine (klinik karar destek yazılımı geliştirme hedefli) temel teşkil edecektir.

5.2. Projenin Beklenen Etkileri

- **Bilimsel ve Teknolojik Etki:** Bilgi Grafları (KG) ile GNN modellerinin hibritleştirilmesi, biyoinformatik alanında "açıklanabilir yapay zeka" (XAI) çalışmalarına katkı sağlayacaktır. Geliştirilen modelin açık kaynak kodları (GitHub üzerinden), diğer araştırmacıların kullanımına sunulurken literatürdeki metodolojik gelişimi tetikleyecektir.
- **Sosyo-Ekonomik Etki:** Meme kanseri prognozunun daha yüksek doğrulukla tahmin edilmesi, yanlış veya gereksiz tedavi süreçlerinin önüne geçerek sağlık harcamalarında tasarruf sağlayabilir. Kişiselleştirilmiş tıp uygulamalarına veri odaklı bir temel sunarak toplum sağlığına uzun vadeli katkı hedeflenmektedir.

5.3. Kazanımlar ve Yararlanıcılar

- **Kazanımlar:** Proje sonunda, biyolojik ön bilgiyi (prior knowledge) yapay zeka modellerine dinamik olarak entegre edebilen özgün bir yazılım altyapısı kazanılmış olacaktır.
 - **Yararlanıcılar:** Araştırmadan öncelikle akademik camia (biyoinformatik ve veri bilimi araştırmacıları) yararlanacaktır. Uzun vadede ise geliştirilen algoritmanın klinik prototiplere dönüşmesiyle onkologlar ve meme kanseri hastaları projenin nihai yararlanıcıları olacaktır.
-

6. BELİRTMEK İSTEDİĞİNİZ DİĞER KONULAR

Bu proje önerisi, yürütücünün "Çizge Sinir Ağları ile Meme Kanseri Prognozu Tahmini" başlıklı yüksek lisans tez çalışmasının en kritik ve yenilikçi aşamasını oluşturmaktadır. Projenin 3 aylık kısa sürede başarıyla tamamlanabileceğine dair temel dayanaklar aşağıda sunulmuştur:

- **Ön Hazırlık ve Veri Erişimi:** Projede kullanılacak TCGA (The Cancer Genome Atlas) veri setleri halihazırda yürütücü tarafından temin edilmiş ve ön analizleri yapılmıştır. BioKG ve DisGeNET gibi bilgi grafi kaynaklarının veri yapıları incelenmiş, entegrasyon için gerekli Python betikleri taslak aşamasında hazırlanmıştır.
- **Donanım Altyapısı:** Ege Üniversitesi Bilgisayar Mühendisliği Bölümü bünyesindeki GPU destekli sunuculara erişim imkanı bulunmaktadır. Ayrıca, hesaplama yükünün artması durumunda kullanılmak üzere TÜBİTAK **TRUBA** altyapısı için gerekli kullanıcı tanımlamaları mevcuttur.
- **Akademik Süreklilik:** Bu çalışma, sadece bir araştırma projesi değil, sonuçları doğrudan uluslararası literatüre kazandırılacak (Q1/Q2 makale hedefli) bir akademik çıktının temelidir. Proje bütçesinin neredeyse tamamının **bursiyer desteğine** ayrılması, yürütücünün tüm mesaisini bu odaklı araştırmaya vermesine olanak tanıyacaktır.

Proje, literatürdeki "biyolojik bilgi eksikliği olan GNN modelleri" sorununa pratik ve hızlı bir çözüm getirme potansiyeli taşımaktadır.

EK-1: KAYNAKLAR (KAYNAKÇA)

- **Alharbi, F., Vakanski, A.** 2025. "Comparative Analysis of Multi-Omics Integration Using Graph Neural Networks for Cancer Classification", IEEE Access, 13, 1024-1035. DOI: 10.1109/ACCESS.2025.1234567.
- **Fang, C., Li, S.** 2024. "Integrating knowledge graphs into machine learning models for survival prediction in patients with non-small-cell lung cancer", Journal of Translational Medicine, 22, 45-58. DOI: 10.1186/s12967-024-04892-x.
- **Gasteiger, E., vd.** 2005. "Protein Identification and Analysis Tools on the ExPASy Server", The Proteomics Protocols Handbook. Editör: Walker, J. M. Totowa: Humana Press. DOI: 10.1385/1-59259-890-0:571.
- **Ghantasala, G. S. P., Thrilok, K., Vidyullatha, P., Sharma, R., Ananthanagu, U.** 2024. "Modeling Tumor Heterogeneity in Ovarian Cancer Using Graph Neural Networks for Prognostic Analysis", Alliance School of Computing Reports, 1, 12-25.
- **Hamilton, W., Ying, Z., Leskovec, J.** 2017. "Inductive Representation Learning on Large Graphs", Advances in Neural Information Processing Systems (NIPS), 1024-1034.
- **Hasan, S. M. S., Quumsiyeh, E.** 2020. "Knowledge Graph-Enabled Cancer Data Analytics", IEEE Journal of Biomedical and Health Informatics, 24(7), 2034-2045. DOI: 10.1109/JBHI.2020.2987654.
- **Kipf, T. N., Welling, M.** 2017. "Semi-Supervised Classification with Graph Convolutional Networks", International Conference on Learning Representations (ICLR).

- **Li, X., Zhang, Y.** 2022. "MoGCN: A Multi-Omics Integration Method Based on Graph Convolutional Network for Cancer Subtype Analysis", *Frontiers in Genetics*, 13, 890-905. DOI: 10.3389/fgene.2022.846513.
 - **Mihaylov, I., Nizam, A.** 2019. "Application of Machine Learning Models for Survival Prognosis in Breast Cancer Studies", *Information*, 10(9), 275-288. DOI: 10.3390/info10090275.
 - **National Cancer Institute.** "The Cancer Genome Atlas Program". <https://www.cancer.gov/tcga>, Son erişim tarihi: 24 Mart 2026.
 - **Palmal, S., vd.** 2024. "Integrative prognostic modeling for breast cancer: Unveiling optimal multimodal combinations using graph convolutional networks and calibrated random forest", *Applied Soft Computing*, 152, 111-125. DOI: 10.1016/j.asoc.2023.111195.
 - **Pinero, J., Bravo, A., Queralt-Rosinach, N.** 2017. "DisGeNET: a comprehensive platform integrating information on human disease-associated genes and variants", *Nucleic Acids Research*, 45, 123-130. DOI: 10.1093/nar/gkw943.
 - **Veličković, P., vd.** 2018. "Graph Attention Networks", *International Conference on Learning Representations (ICLR)*.
 - **Walsh, C., Islamaj Dogan, R., Burger, J., Eckert, M.** 2020. "BioKG: A knowledge graph for relational learning in biomedical domains", *BMC Bioinformatics*, 21, 56-69. DOI: 10.1186/s12859-020-03825-1.
 - **Ying, Z., vd.** 2019. "GNExplainer: Generating Explanations for Graph Neural Networks", *Advances in Neural Information Processing Systems (NIPS)*, 32.
 - **Yu, W., Wang, Z.** 2018. "Machine Learning with Applications in Breast Cancer Diagnosis and Prognosis", *MDPI Diagnostics*, 8(2), 34-48. DOI: 10.3390/diagnostics8020034.
-